

Fourier Encoding (Фурье-кодирование)

Проблемы PINN


Разное соотношение частей loss-функции:




Рис. 1 – Loss-функция

Проблемы PINN I


Spectral bias (спектральное смещение).



(a) 2000 эпох



(b) 5000 эпох



(c) 16 000 эпох

Рис. 2 – Обучение NN копировать функцию $\sin(x) + \sin(5x)$





Рис. 3 – История обучения



(a) True



(b) Step 80



(c) Step 2000



(d) Step 58 000

Хорошо это или плохо? I

С одной стороны, при решении уравнений, функции-решения которых содержат высокочастотные составляющие, потеря высоких частот приводит к неправильному решению или долгому обучению. С другой стороны, если эксперимент достаточно шумный, то происходит естественная фильтрация шумов. Например, в статье [1] используется специальный фильтрующий автоэнкодер, чтобы удалять шумы.

Хорошо это или плохо? II




Рис. 4 – Обучить нейросеть копировать шумное поле (а) достаточно сложно, но этого и не надо делать.






Рис. 5 – Denoising image-based experimental data without clean targets based on deep autoencoders [1]

Когда это плохо I

Волновое уравнение с высокими частотами




(a)




(b)

Когда это плохо II



(a)






Figure 18: *2D Gray-Scott equation*: Results obtained by training a fully-connected network (9 layers, 100 hidden units, tanh activations) after 120,000 iterations of gradient descent. (a)(b) Numerical estimations versus the predicted concentration fields u, v respective at the final time $t = 4000$. (c) Relative L^2 errors between the model predictions and the corresponding exact concentration fields for each snapshot $t \in [3500, 4000]$. (d) Evolution of the inferred diffusion rates ϵ_1, ϵ_2 during training.




Figure 17: *2D Gray-Scott equation*: Results obtained by training a fully-connected network (9 layers, 100 hidden units, tanh activations) with the spatio-temporal Fourier feature mappings after 120,000 iterations of gradient descent. (a)(b) Numerical estimations versus the predicted concentration fields u, v respective at the final time $t = 4000$. (c) Relative L^2 errors between the model predictions and the corresponding exact concentration fields for each snapshot $t \in [3500, 4000]$. (d) Evolution of the inferred diffusion rates c_1, c_2 during training.

Фурье-кодирование




Рис. 6 – Схема PINN с дополнительным слоем Фурье-кодирования. (a) Пространственные входы, (b) пространственно-временные входы.

Структура слоев

$$\gamma_x^{(i)}(x) = \begin{bmatrix} \cos\left(2\pi B_i^{(x)} x\right) \\ \sin\left(2\pi B_i^{(x)} x\right) \end{bmatrix}, \quad H_{x,1}^{(i)} = \phi\left(W_1 \cdot \gamma_x^{(i)}(x) + b_1\right), \quad i = 1, 2, \dots, M_x, \quad (1)$$

$$\gamma_t^{(j)}(t) = \begin{bmatrix} \cos\left(2\pi B_j^{(t)} t\right) \\ \sin\left(2\pi B_j^{(t)} t\right) \end{bmatrix}, \quad H_{t,1}^{(j)} = \phi\left(W_1 \cdot \gamma_t^{(j)}(t) + b_1\right), \quad j = 1, 2, \dots, M_t, \quad (2)$$

$$H_{x,\ell}^{(i)} = \phi\left(W_\ell \cdot H_{x,\ell-1}^{(i)} + b_\ell\right), \quad \ell = 2, 3, \dots, L, \quad i = 1, 2, \dots, M_x, \quad (3)$$

$$H_{t,\ell}^{(j)} = \phi\left(W_\ell \cdot H_{t,\ell-1}^{(j)} + b_\ell\right), \quad \ell = 2, 3, \dots, L, \quad j = 1, 2, \dots, M_t, \quad (4)$$

$$H_L^{(i,j)} = H_{x,L}^{(i)} \odot H_{t,L}^{(j)}, \quad i = 1, 2, \dots, M_x, \quad j = 1, 2, \dots, M_t, \quad (5)$$

$$f_\theta(x, t) = W_{L+1} \left[H_L^{(1,1)}, \dots, H_L^{(M_x, M_t)} \right] + b_{L+1}. \quad (6)$$

Здесь $\gamma_x^{(i)}$ и $\gamma_t^{(j)}$ обозначают пространственные и временные отображения признаков соответственно, а $\odot$ обозначает поэлементное произведение. Параметры $B_i^{(x)}$ и $B_j^{(t)}$ выбираются из $\mathcal{N}(0, \sigma_x^2)$ и $\mathcal{N}(0, \sigma_t^2)$ соответственно и фиксируются на протяжении всего процесса обучения модели [2].

Отдельный класс для слоя с Фурье-преобразованием I

```
class FourierFeatureEmbedding(nn.Module):  
  
    def __init__(self, in_dim, mapping_size, scale=10.0):  
        super().__init__()  
        self.B = torch.randn(in_dim, mapping_size) * scale *  
            2 * torch.pi  
  
    def forward(self, v):  
        proj = torch.matmul(v, self.B)  
        return torch.cat([torch.cos(proj), torch.sin(proj)],  
            dim=-1)
```

И далее в основном классе с NN прописывать:

```
self.fourier_embedding = FourierFeatureEmbedding(  
    in_dim, mapping_size, scale)
```

1. Denoising image-based experimental data without clean targets based on deep autoencoders. /. — G. Feng [и др.] // Experimental Thermal and Fluid Science. — 2024. — Т. 156. — С. 111195.
2. *Wang S., Wang H., Perdikaris P.* — On the eigenvector bias of fourier feature networks: From regression to solving multi-scale pdes with physics-informed neural networks. — // Computer Methods in Applied Mechanics and Engineering. — 2021. — Т. 384. — С. 113938.